

Ekilex ja Sõnaveeb rakenduste paigaldusjuhend

TripleDev, Martin Laubre

Sisukord


Sissejuhatus.....	4
Tarkvara paigaldamine.....	5
Baas-tarkvara.....	5
Java.....	5
Apache HTTP	5
Apache Maven.....	5
Postgres.....	6
Apache Tomcat.....	6
Git.....	6
Rakendustarkvara.....	7
Tarkvaraprojekt Ekilex.....	7
Veebirakendus Ekilex.....	8
Lähtekood.....	8
Konfigureerimine.....	8
Andmebaasi struktuuride loomine.....	9
Ehitamine.....	10
Käivitamine.....	10
Kasutajate juurdepääs.....	12
Kasutaja kasutustingimustega nõustumine.....	12
Veebirakendus Sõnaveeb (Wordweb).....	12
Lähtekood.....	12
Konfigureerimine.....	12
Andmebaasi struktuuride loomine.....	13
Ehitamine.....	14
Käivitamine.....	14
Sõnakogude laadurid.....	15
Lähtekood.....	16
Konfigureerimine.....	16
Ehitamine.....	16
Käivitamine.....	17
Sõnakogude laadimine.....	17
Ekilex.....	17
Sõnaveeb.....	17
Mängude laadimine.....	18
Ekilex.....	18
Sõnaveeb.....	18
Andmetöötlusutiliidid.....	19
Sõnakogude liitmine (ühekordne).....	19
Homonüümide ühendamine (ühekordne).....	19
Tähenduste ühendamine (ühekordne).....	20
Samakujuliste keelendite ühendamine.....	20
Korduvate tähendusnumbrite korrigeerimine.....	21
Vene keele rõhkude teisendamine.....	21

Vene ja ladina homonüümide ühendamine.....	21
Homonüüminumbrite järjestamine.....	22
Sõnonüümikandidaatide genereerimine.....	22
Sõnakogude eksportimine.....	23
Sõnakogude importimine.....	23
Ekspluatatsiooni märkused.....	24
Kasutajatega seotud kirjade varundamine sõnakogude täis-laadimisel.....	24
Rakenduse URL kodeeringute probleemistik.....	24
Sõnakogude haldus ja õigused.....	25
Uuenevate tarkvaraversioonide migratsioon.....	25
Lisad.....	26
Andmeparandusskriptid.....	26
Vastete järjestuse taastamine komponentsõnakogudest.....	26
Lihtsate vene vastete järjestuse nihutamine detailsetest tahapoole.....	26
Tarbetu vene rõhu märgenduse eemaldamine.....	26
Homonüüminumbrite järjestamine.....	27

Sissejuhatus

Järgnev juhend kirjeldab kahe autonoomse rakenduse, Ekilex ja Sõnaveeb ning nendega seotud baas-tarkvara paigaldamist.

Soovitav arhitektuur on ilmetatud järgneva joonisega:



Joonis 1. Arhitektuur

Kuna Ekilexil ja Sõnaveebil on erinevad kasutajad ning sellest tingitud erinevad süsteemi jõudluse eeldused, siis peavad rakendused asuma füüsiliselt erinevates serverites. Kummagi rakenduse jaoks tuleb teha eraldi täielik paigaldus baas-tarkvarast alates.

Sõnaveebi reaalsetest päringumahtudest tingitult on võimalik lisada jõudlust läbi andmebaasi ja rakenduse füüsilise lahutamise ning andmebaasi ja/või rakenduse klaster-konfiguratsiooni, kuid

seda siis kui selleks reaalne vajadus tekib. Esialgu käesolev juhend sellist konfiguratsiooni ei käsitle. Samuti ei käsitle käesolev juhend vabavaralise baas-tarkvaraga seotud spetsiifilisi määranguid ja häälestusi. Vastavad juhendid individuaalselt parima konfiguratsiooni koostamiseks on veebis vabalt leitavad.

Tarkvara paigaldamine

Baas-tarkvara

Java

Paigalda Java rakenduste virtuaalmasin Java JDK ver 8. Operatsioonisüsteemile sobiv versioon leia siit:

<http://www.oracle.com/technetwork/java/javase/downloads/index.html>

<http://www.oracle.com/technetwork/java/javase/downloads/jdk8-downloads-2133151.html>

Apache HTTP

Rakendusserver on avaliku veebiliikluse eest varjatud Apache HTTP serveriga, mis klaster-konfiguratsiooni puhul käitub kui tarkvaraline koormusjaotur. Operatsioonisüsteemile sobiv versioon leia siit:

<https://httpd.apache.org/download.cgi>

Kindlasti paigalda ja konfigureeri HTTP serveris SSL sertifikaat, et rakenduse veebiliiklus käiks üle https protokollile. Täienda hiljem HTTP serveri määranguid reaalsete rakenduse viidetega kui need ükskord paigaldatud saavad. Sulge igasugune muu juurdepääs rakendusserveritele. Rakenduse viite näidis:

```
<Location /wordweb>
  ProxyPass          ajp://localhost:5577/wordweb nocanon
  ProxyPassReverse   ajp://localhost:5577/wordweb
</Location>
```

Apache Maven

Paigalda tarkvara ehitamise ja sõltuvuste halduse raamistik Apache Maven.

<https://maven.apache.org/download.cgi>

<http://www-eu.apache.org/dist/maven/maven-3/3.5.3/binaries/>

Käitu vastavalt juhendile:

<https://maven.apache.org/install.html>

Oluline on, et Maveni määrangud viitaksid korrektsele Java JDK-le.

Postgres

Paigalda andmebaasi tarkvara Postgres ver 9.6
Operatsioonisüsteemile sobiv versioon leia siit:

<https://www.postgresql.org/download/>

Ehkki Postgres andmebaasi vaikemäärangud on piisava jõudluse tagamiseks enamasti sobivad, siis saab jõudlust oluliselt tõsta andmebaasi kasutamise iseloomu ja reaalsel raudvara arvestades. Hea abivahend määrangute häälestamiseks asub siin:

<https://pgtune.leopard.in.ua/>

Loodud andmebaasi serveritesse loo vastava rakenduse andmebaas ja süsteemne kasutaja.

Rakendus Ekilex:

Andmebaas:	ekilex
Kasutaja:	ekilex
Skeem:	public (vaikimisi)
Kodeering (<i>encoding</i>):	UTF8
Tähestik (<i>collation</i>):	et_EE.UTF-8

Rakendus Sõnaveeb:

Andmebaas:	wordweb
Kasutaja:	wordweb
Skeem:	public (vaikimisi)
Kodeering (<i>encoding</i>):	UTF8
Tähestik (<i>collation</i>):	et_EE.UTF-8

Apache Tomcat

Rakendustarkvara rakendusserveriks on Apache Tomcat (<http://tomcat.apache.org/>). Antud juhul Tomcat serverit siiski eraldi paigaldama ei pea, sest rakendused Ekilex ja Sõnaveeb kasutavad Spring Boot Tomcat pistakut, mille vahendusel käivitatakse rakendus nõ virtuaalses Tomcat ümbrises (*wrapper container*).

Git

Paigalda tarkvara versioneerimise ja säilitamise tehnoloogia Git.

Operatsioonisüsteemile sobiv versioon leia siit:

<https://git-scm.com/downloads>

Git kasutamise eelduseks on kasutajakonto olemasolu GitHub-s:

<https://github.com/>

Rakendustarkvara

Ekilex ja Sõnaveeb rakenduste lähtekoodi struktuur ning tarkvara ehitamise ja käivitamise mehhanism on samasugused. Seepärast on Ekilex rakenduse juhend detailsem ning Sõnaveebi juhend väldib korduvusi.

Tarkvaraprojekt Ekilex

Ekilex tarkvaraprojekti lähtekood asub siin:

`https://github.com/tripledev/ekilex.git`

Kui Git klientrakendus on konfigureeritud kasutama SSH privaatvõtit, siis alternatiivselt on lähtekoodi asukohaks:

`git@github.com:tripledev/ekilex.git`

Lae lähtekood kohalikus failisüsteemis kindlasse asukohta kuhu on mugav navigeerida ja tarkvara ehitamine käivitada. Ära kasuta tühikuid sisaldavate nimedega katalooge! Selle juhendi ulatuses on tinglikult selliseks kataloogiks

`/apps/source>`

Järgnev korraldus laeb alla kogu Ekilex tarkvara projekti, mille alamosadeks on Ekilex ja Sõnaveebi moodulid.

`/source>git clone https://github.com/tripledev/ekilex.git`

Navigeeri allalaetud tarkvara projekti juur-kataloogi `ekilex`

Allalaetud lähtekood esitab vaikumisi „master“ arendusharu seisu, mis pole ettenähtud toodangu režiimisi rakendamiseks. Toodangu jaoks on kokkulepitud stabiliseeritud versioon, mis asub mingis kindlas harus (*branch*) või *tag*-s. Sobivasse harusse ümberlülitumine käib käsuga

`/ekilex>git checkout x.x.x`

kus `x.x.x` on vastava haru nimi, mis tõenäoliselt on tarkvara versiooni number, näiteks `1.0.0`
Kõikide eksisteerivate harude nimekirja saab käsuga:

```
/ekilex>git branch
```

Ekilex ja Sõnaveeb rakenduste käivitamise eelduseks on keskkonna-spetsiifiliste määrangutega lähtekoodist ehitatud artefaktid

Veebirakendus Ekilex

Lähtekood

Ekilex rakenduse lähtekood asub tarkvara projekti alamkataloogis

```
/ekilex/ekilex-app>
```

Konfigureerimine

Peale lähtekoodi allalaadimist ja õigesse harusse ümberlülitumist, konfigureeri toodangukeskkonna-spetsiifiliste määrangute fail

```
/ekilex/ekilex-app/src/main/resources/application-prod.properties
```

Rakenduvad kõik määrangud `application.properties` ja valitud profiili (prod) laiendiga `application-prod.properties` faili peale kokku kusjuures profiili laiendiga fail on kõrgema prioriteediga. Seepärast ei ole vaja `application-prod.properties` failis kirjeldada määranguid, mis `application.properties` failis juba sobival kujul eksisteerivad. Samas saab `application-prod.properties` määrangutega kirjutada üle sobimatud määrangud `application.properties` failis. Olulised on järgmised parameetrid.

Rakendusserver:

```
server.port  
server.servlet.context-path  
server.servlet.session.timeout
```

```
tomcat.ajp.port  
tomcat.ajp.enabled
```

AJP määrangud reguleerivad rakendusserveri ja avalikku veebi eksponeeriva HTTP serveri vahelist kommunikatsiooni. AJP port peab kindlasti erinevama HTTP pordist. AJP protokoll kasutamine rakendusserveri ja HTTP serveri vahel on tungivalt soovitatav. Rakendusserveri määrangud peavad olema sellised, et need oleks võimalik avaliku veebi eest varjata.

Andmebaasi ühenduse kirjeldus:

```
spring.datasource.url  
spring.datasource.username  
spring.datasource.password
```


Vastav loogiline andmebaas tuleb eelnevalt füüsilisse andmebaasi luua. Võimalik, et loogilise andmebaasi nimi ja kasutaja juba sobivadki. Samuti, kui andmebaas ja rakendus asuvad samas füüsilises serveris, võiks ka localhost url sobida.

Failiressursid – pildid, hääldused, jms. Sisu kohta küsi täpsemalt arendajatelt.

`file.repository.path`

Kasutajate registreerimisega seotud määrangud:

```
ekilex.app.url
email.sending.enabled
email.from.address
email.from.name
spring.mail.host
spring.mail.port
spring.mail.username
spring.mail.password
spring.mail.properties.mail.smtp.auth
spring.mail.properties.mail.smtp.starttls.enable
```

Logimise detailsus:

```
logging.level.root
logging.level.eki.ekilex
logging.level.eki.common
logging.level.org.jooq
```

Vaikimisi on rakenduse enda logid debug detailsusega, muud sõltuvused pääsevad läbi ainult warn taseme detailsusega. Alustuseks võib just selline logi detailsus olla isegi hea mõte.

Logifail:

```
logging.path
logging.file
```

Failinime (logging.file) võiks muuta ainult juhul kui sellest rakendusest on plaan käivitada mitu erinevat instantsi. Reaalselt rikastatakse failinime veel kuupäevaga. Oluline on määrata logifailile asukoha absoluutne rada (logging.path) kuhu eri päevade logifailid kogunema hakkavad. Kui rada ei eksisteeri, see luuakse kui rakendust käivitaval kasutajal on selleks operatsioonisüsteemi mõistes vajalikud õigused.

Andmebaasi struktuuride loomine

Kõik andmebaasi struktuuride loomise ja baasandmetega täitmise skriptid asuvad kataloogis

```
/ekilex/ekilex-app/src/main/resources/sql/
```

Oluline! Kui sõnakogude laadimiseks kasutada sõnakogude mass-laadijat (*UltimaLoader*), siis pole nende skriptide käivitamine vajalik – laadur teeb seda ise.

Ehitamine

Peale rakenduse konfigureerimist tuleb rakenduse lähtekoodist ehitada rakenduslik artefakt. Alustuseks tuleb ehitada kogu tarkvara projekt, mis loob ja laeb alla kohalikku Maven repositooriumisse nii selle tarkvaraprojekti moodulite artefaktid kui kõik nendele moodulitele vajalikud sõltuvused kesketest Maven repositooriumitest. Esmakordne ehitamine võib kesta minuteid.

```
/ekilex>mvn clean install -D skipTests
```

Ehitamine õnnestus kui protsessi lõpuks on kuvatud teade: „BUILD SUCCESS“

Ehitamise ebaõnnestumisest annab märku teade: „BUILD FAILURE“

Ebaõnnestunud ehitamise põhjus on kirjeldatud samas protsessi logis.

Edaspidi, kui on vaja muuta ainult vastava rakenduse määranguid, võib ehitamist käivitada selle rakenduse juures

```
/ekilex/ekilex-app>mvn clean install -D skipTests
```

Võti `skipTests` on vajalik kui kohalikult pole seadistatud automaatsete andmebaas. Igalpool mujal kui toodanguserveris, kus toimub lähtekoodi muutmine võiks automaatsete andmebaasi siiski konfigureerida ning ehitamine käivitada ilma `-D skipTests` määranguta, sest siis on eduka ehitamise protsessi eelduseks ka positiivse tulemusega automaatsetid.

Käivitamine

Edukalt ehitatud rakenduse käivitamisel tuleb valida korrektne profiil (prod). Et kontrollida rakenduse konfigureerimise ja ehitamise edukust, saab seda testimiseks käivitada kahel viisil:

Maven pistaku vahendusel:

```
/ekilex/ekilex-app>mvn spring-boot:run -D spring-boot.run.profiles=prod
```

Otse Java rakendusena ehituse tulemi pealt:

```
/ekilex/ekilex-app/target>java -jar ekilex-app.jar --spring.profiles.active=prod
```

Kui rakendus käivitub normaalselt, on võimalik hakata jälgima rakenduse logi määratletud logifailis.

Selline rakenduse käivitusviis sobib siiski ainult ehitamise ja konfigureerimise edukuse testimiseks.

Reaalselt on tungivalt soovitatav käivitada rakendus systemd teenusena.

Loo sobiv Linux kasutaja, kellena rakendust hakatakse käivitama. See ei tohiks olla root kasutaja!

Käesolevas juhendis on selleks kasutajaks `ekilex`

Kopeeri rakenduse ehituse tulemi kataloogist rakenduse artefakt `ekilex-app.jar` sobivasse kataloogi. Selle juhendi ulatuses on tinglikult selliseks kataloogiks

```
/apps/deploy/ekilex>
```

Loo fail

```
/etc/systemd/system/ekilex.service
```

Sisusta fail järgmisega:

```
[Unit]
Description=EKILEX application
After=syslog.target
```

```
[Service]
User=ekilex
ExecStart=/apps/deploy/ekilex/ekilex-app.jar
WorkingDirectory=/apps/deploy/ekilex
Environment="JAVA_HOME=/opt/jdk1.8.0_144"
SuccessExitStatus=143
```

```
[Install]
WantedBy=multi-user.target
```

Loo rakenduse artefakti naabrusesse täiendavate määrangute fail, mis kannab sama nime kuid on erineva faililaiendiga:

```
/apps/deploy/ekilex/ekilex-app.conf
```

Sisusta fail järgmisega:

```
JAVA_OPTS=-Xmx4096M
RUN_ARGS=--spring.profiles.active=prod
```

Teenus on valmis kasutamiseks

```
/>systemctl start ekilex
/>systemctl restart ekilex
/>systemctl stop ekilex
```

Kasutajate juurdepääs

Ekilexi kasutamine on kaitstud autoriseerimisega. Kasutajad saavad ennast ise registreerida. Registreerimise protseduur sisaldab kinnituskirja saatmist kasutaja määratud e-posti aadressile. Kiri sisaldab linki, millega kasutaja oma registreerimist kinnitab. Kirja link on seotud ekilex rakenduse määrangutes kirjeldatud rakenduse aadressi.

Kasutaja kasutustingimustega nõustumine

Kasutaja registreerimisel küsitakse kasutajalt kinnitust Ekilexi kasutustingimustega.

Kasutustingimustega nõustumine on registreerimise eelduseks.

Kasutustingimuste tekst asub staatilisel kujul otse html-failis:

```
ekilex/ekilex-app/src/main/resources/view/html/terms.html
```

Kasutustingimuste versiooninumber on tekstilisel kujul rakenduse määrangute failis:

```
/ekilex/ekilex-app/src/main/resources/application-prod.properties
```

Võti:

```
terms.version=1.0
```

Vastav kehtiv väärtus salvestatakse kasutaja andmetesse kirje loomisel. Tulevikus saab luua selle baasil vajalik funktsionaalne loogika uuenevate kasutustingimuste versioonide kinnitamiseks endiste kasutajate jaoks.

Veebirakendus Sõnaveeb (Wordweb)

Lähtekood

Sõnaveebi rakenduse lähtekood asub tarkvara projekti alamkataloogis

```
/ekilex/wordweb-app>
```

Konfigureerimine

Konfigureeri toodangukeskkonna-spetsiifiliste määrangute fail

```
/ekilex/wordweb-app/src/main/resources/application-prod.properties
```

Rakendusserver:

```
server.port  
server.servlet.context-path  
server.servlet.session.timeout
```

```
tomcat.ajp.port  
tomcat.ajp.enabled
```

Rakendusserveri tööstatistika pistaku Actuator juurdepääsu kirjeldus:

```
spring.security.user.name  
spring.security.user.password  
spring.security.user.roles
```

Andmebaasi ühenduse kirjeldus:

```
spring.datasource.url  
spring.datasource.username  
spring.datasource.password
```

Failiressursid:

```
file.repository.path
```

Välisliidesed – kõnesüntesaator, kõnetuvastus, eesti ja vene korpused.

```
speech.synthesizer.service.url  
speech.recognition.service.url  
corpora.service.est.url  
corpora.service.est.corpname  
corpora.service.rus.url  
corpora.service.rus.corpname  
corpora.service.rus.username  
corpora.service.rus.api.key
```

Kasutajate tagasiside link ekilex suunas:

```
wordweb.feedback.service.url
```

Logimise detailsus:

```
logging.level.root  
logging.level.eki.ekilex  
logging.level.eki.common  
logging.level.org.jooq
```

Logifail:

```
logging.path  
logging.file
```

Andmebaasi struktuuride loomine

Sõnaveebi andmebaas koosneb peamiselt materialiseeritud vaadetest (*materialized views*), mis

koostatakse üle andmebaasi side-ühenduse (*dblink*) Ekilexi andmete pealt. Kõik andmebaasi struktuuride loomise ja andmetega täitmise skriptid asuvad kataloogis

```
/ekilex/wordweb-app/src/main/resources/sql/
```

`create_mviews.sql` – kõikide materialiseeritud vaadete loomine ja sisustamine sõnakogude andmetega ja klassifikaatoritega

`create_tables.sql` – kõikide tabelite loomine ja sisustamine mängude andmetega

Esmakordsel konfigureerimisel tuleb Sõnaveebi andmebaasis aktiveerida andmebaasi laiend *dblink*. See käib andmebaasi terminalis käsuga:

```
CREATE EXTENSION dblink;
```

Vajalikku side-ühendust kahe andmebaasi vahel saab testida käsuga:

```
SELECT dblink_connect('host=localhost user=ekilex password=<parool> dbname=ekilex');
```

Modifitseeri selle päringu parameetreid vastavalt reaalsele Ekilex konfiguratsioonile.

Edukas ühendus kahe andmebaasi vahel tagastab tulemuseks „OK“

Ehitamine

Kogu tarkvaraprojekti ehitamine:

```
/ekilex>mvn clean install -D skipTests
```

Sõnaveebi rakenduse ehitamine:

```
/ekilex/wordweb-app>mvn clean install -D skipTests
```

Käivitamine

Maven pistaku vahendusel:

```
/ekilex/wordweb-app>mvn spring-boot:run -D spring-boot.run.profiles=prod
```

Otse Java rakendusena ehituse tulemi pealt:

```
/ekilex/wordweb-app/target>java -jar wordweb-app.jar --spring.profiles.active=prod
```

Käivitamine teenusena. Vajalikud eeldused.

Kopeeri rakenduse artefakt `wordweb-app.jar` kataloogi:

```
/apps/deploy/wordweb>
```

Loo fail

```
/etc/systemd/system/wordweb.service
```

Sisusta fail järgmisega:

```
[Unit]
```

```
Description=WORDWEB application
```

```
After=syslog.target
```

```
[Service]
```

```
User=wordweb
```

```
ExecStart=/apps/deploy/wordweb/wordweb-app.jar
```

```
WorkingDirectory=/apps/deploy/wordweb
```

```
Environment="JAVA_HOME=/opt/jdk1.8.0_144"
```

```
SuccessExitStatus=143
```

```
[Install]
```

```
WantedBy=multi-user.target
```

Loo rakenduse artefakti naabrusesse fail:

```
/apps/deploy/wordweb/wordweb-app.conf
```

Sisusta fail järgmisega:

```
JAVA_OPTS=-Xmx4096M
```

```
RUN_ARGS=--spring.profiles.active=prod
```

Teenus on valmis kasutamiseks

```
/>systemctl start wordweb
```

```
/>systemctl restart wordweb
```

```
/>systemctl stop wordweb
```

Sõnakogude laadurid

Hetkel on võimalik sõnakogusid Ekilexi laadida ainult EKI oma XML-vormingus failidest.

Peale Ekilexi sõnakogude laadimist on võimalik need edasi laadida Sõnaveebi.

Ekilexi saab sõnakogusid laadida nii ükshaaval kui korraga.

Oluline on teada, et laadimine toimub käsurareakendustega, mille tehnoloogiline koosseis on erinev veebirakendustest ning seetõttu on erinev ka konfigureerimine ja käivitamine.

Lähtekood

Laadurite käsurearakenduste lähtekood asub tarkvara projekti alamkataloogis

```
/ekilex/ekilex-etl>
```

Konfigureerimine

Konfigureeri toodangukeskkonna-spetsiifiliste määrangute faili

```
/ekilex/ekilex-etl/envresources/prod/ekilex-etl.properties
```

Ekilex rakenduse andmebaasi ühenduse kirjeldus:

```
db.ekilex.url  
db.ekilex.usr  
db.ekilex.psw
```

Termeki andmebaasi ühenduse kirjeldus:

```
db.termeki.url  
db.termeki.usr  
db.termeki.psw
```

Termeki failide teenuse kirjeldus ja kohalik failide laadimise sihtkataloog:

```
termeki.file.service.url  
file.repository.path=/apps/data/files/
```

Kui on plaanis kasutada universaalset kõigi sõnakogude mass-laadijat, siis tuleb konfigurida ka järgmine fail:

```
/ekilex/ekilex-etl/envresources/prod/ultima-loader.properties
```

Logimise määrangud asuvad:

```
/ekilex/ekilex-etl/envresources/prod/logback.xml
```

Ehitamine

Kogu tarkvaraprojekti ehitamine:

```
/ekilex>mvn clean install -D skipTests
```

Sõltuvalt millist laadurit on soov käivitada, võib ehitamine olla erinev. Täpsemalt sellest peatükis „Sõnakogude laadimine“

Käivitamine

Erinevate laadurite käivitamisest räägib peatükk „Sõnakogude laadimine“

Sõnakogude laadimine

Ekilex

Hetkel käsitleb juhend ainult universaalset kõigi sõnakogude mass-laadijat (*UltimaLoader*), mis käivitamisel täielikult tühjendab määratud andmebaasi (isfullreload=true) ning laeb sinna järjest kõik määratud sõnakogud. Ettevaatust!

Peale määrangufailide konfigureerimist, enne käivitamist, tuleb vastav rakendus ehitada.

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvall
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvall
```

Laadimise edenemist ja õnnestumist saab jälgida määratud logifailist. Sõnakogud on laetud, kui logi lõppeb teatega: „DONE LOADING DATASETS!!“

Sõnakogusid saab laadida ka üks-haaval või väiksema grupina. Ettevaatlik tuleb siiski olla ühendatud keelendite ja tähendustega sõnakogude puhul.

Eelnevalt seadistada failis `ultima-loader.properties` määrang:

```
isfullreload=false
```

Käivitamine:

```
/ekilex/ekilex-etl>  
mvn exec:java -Pprodsrvall -Dexec.args="<dataset1> <dataset2> <dataset3>"
```

Sõnaveeb

Sõnakogude Sõnaveebi laadimine ning hiljem värskendamine toimub üle andmebaaside side-ühenduse (DB link) andmebaasi vaadete (view) vahendusel. Andmebaaside side-ühendamisest on juttu Sõnaveebi rakenduse konfigureerimise juures.

Sõnakogude algne laadimine toimub andmebaasi skriptiga, mis asub tarkvaraprojekti lähtekoodis:

```
/ekilex/wordweb-app/fileresources/sql/create_mviews.sql
```

See skript kustutab eksisteerivad, loob uued materialiseeritud vaated (*materialized views*) vastavate Ekilex andmebaasi vaadete pealt ning indekseerib need vaated.

Modifitseeri skriptis andmebaasi side-ühenduse parameetreid.

Ära unusta lõpetada skript käsuga:

```
commit;
```

Edaspidi tuleb materialiseeritud vaadete loomise skripti `create_mviews.sql` käivitada alati kui Ekilexi või Sõnaveebi andmemudelisse tehakse muudatusi.

Kui aga Ekilexis muutuvad ainult andmed, siis piisab materialiseeritud vaadete värskendamisest:

```
refresh materialized view mview_ww_word;  
refresh materialized view mview_ww_as_word;  
refresh materialized view mview_ww_word_etymology;  
refresh materialized view mview_ww_form;  
refresh materialized view mview_ww_meaning;  
refresh materialized view mview_ww_lexeme;  
refresh materialized view mview_ww_collocation;  
refresh materialized view mview_ww_classifier;  
refresh materialized view mview_ww_dataset;  
refresh materialized view mview_ww_word_relation;  
refresh materialized view mview_ww_lexeme_relation;  
refresh materialized view mview_ww_meaning_relation;
```

Oluline! Sõnaveebi detailsuse-põhine agreegeerimine ja sellega seotud päringud on alles töös ning ei tööta hetkel vigadeta. Üks Sõnaveebi agreegeerimise eelduseid on see, et senine andmebaasivaadete koostamine „ss1“, „psv“, „qq2“, „ev2“ põhjalt on asendunud ühe summa-sõnakoguga „sss“, mis tuleb koostada eraldi tegevusena peale sõnakogude laadimist. Vt. „Sõnakogude liitmine“

Mängude laadimine

Ekilex

Sõnaveebi mängude alusandmed koostatakse kombineeritult sõnakogude andmetest ja täiendava(te)st andmefaili(de)st automaatselt koos sõnakogude laadimisega mass-laadija (*UltimaLoader*) poolt. Andmefailide asukoht on kirjeldatud `ultima-loader.properties` failis.

Sõnaveeb

Mängude algne laadimine toimub andmebaasi skriptiga, mis asub tarkvaraprojekti lähtekoodis:

```
/ekilex/wordweb-app/fileresources/sql/create_tables.sql
```

See skript kustutab eksisteerivad, loob uued tabelid kõigi mängude jaoks ning sisustab üle andmebaasi side-ühenduse andmetega Ekilexist. Ühtlasi luuakse tabelid mängude tulemuste salvestamiseks. Seetõttu olla ettevaatlik selle skripti korduval kasutamisel kui mängude tulemuste tabelid sisaldavad juba reaalse kasutajate mängude tulemusi.

Andmetöötlusutiliidid

Sõnakogude liitmine (ühekordne)

Peale sõnakogude laadimist on võimalik liita ühendatud keelendite ja tähendustega sõnakogusid uueks summa-sõnakoguks. Liitmist on võimalik käivitada korduvalt. Liitmise protsessi alguses kustutatakse eelnevalt summa-sõnakogu täielikult kui selline peaks varasemalt eksisteerima. Vastavad määrangud asuvad failis:

```
/ekilex/ekilex-etl/envresources/prod/ultima-loader.properties
```

```
lex.merge.name  
lex.merge.dataset
```

lex.merge.name – summa-sõnakogu kood. Kui pole veel loodud, luuakse automaatselt
lex.merge.dataset – tühikuga eraldatud liidetavate sõnakogude koodid

Peale määrangufailide konfigureerimist, enne käivitamist, tuleb vastav rakendus ehitada.

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvlexsum
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvlexsum
```

Oluline teave!

On selgunud, et sõnakogude liitmise utiliit on rikkunud kopeerimisel sünonüümide ja vastete järjekordi tähendustes. Selle kompenseerimiseks on loodud andmebaasi parandusskript, mis taastab järjestused komponentsõnakogudest.

Vaata: Lisad > Andmeparandusskriptid > Vastete järjestuse taastamine komponentsõnakogudest

Homonüümide ühendamise (ühekordne)

Loodud on automaatne homonüümide ühendamise rakendus, mis tuvastab ja ühendab homonüümid kõigis terminoloogilistes sõnakogudes ja etümoloogia sõnakogus (ety) järgnevate reeglite järgi:

- võtta aluseks keelend etteantud sõnakogus (ss1) kui selles esineb ainult üks samakujuline keelend, mis ei ole afiksoid, ei ole lühend ning kustutada muud sellised homonüümid
- kui aluseks määratud sõnakogus üldse sellisekujuline keelend puudub, siis liita kõikide teiste sõnakogude homonüümid üheks ja kustutada muud sellised homonüümid

Rakendust võib käivitada korduvalt.

Rakendust on soovitatav käivitada iga kord kui mõni uus sõnakogu on laetud.

Homonüümide ühendamise aluseks võetud sõnakogu määramine käib failis:

```
/ekilex/ekilex-etl/envresources/prod/ultima-loader.properties
```

```
word.merge.dataset
```

Peale määrangufailide konfigureerimist, enne käivitamist, tuleb vastav rakendus ehitada.

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvwordsum
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvwordsum
```

Tähenduste ühendamine (ühekordne)

Loodud on käsureapõhine rakendus, mis kogub etteantud liitsõnakogust (sss) erinevate andmetunnuste järgi tuletades komponentsõnakogude (ss1, psv, kol, qq, ev) tähendused, mis tõenäoliselt on samatähenduslikud ja liidab need üheks. Leitud tähendustega seotud andmed kolitakse kordumatult sihttähenduste juurde ja liigsed komponenttähendused kustutatakse. Rakendust võib käivitada korduvalt. Enne käivitamist pööra tähelepanu eeldustele!

Vaikimisi määrab vastav ehitamise/käivitamise profiil terminalipõhise logimise.

Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvmeaningsum
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvmeaningsum  
-Dexec.args="<compound dataset>"
```

compound dataset – liitsõnakogu, tõenäoliselt „sss“

Eeldused enne käivitamist!

- Käivita skript: Lisad > Andmeparandusskriptid > Vastete järjestuse taastamine komponentsõnakogudest
- Käivita skript: Lisad > Andmeparandusskriptid > Lihtsate vene vastete järjestuse nihutamine detailsetest tahapoole
- Kustuta komponentsõnakogud ss, psv, kol, qq, ev. Vastasel juhul tekib tähenduste liitmise tagajärjel massiliselt osalise andmestikuga duplikaat-tähendusi

Samakujuliste keelendite ühendamine

Loodud on käsureapõhine rakendus, mis kogub tähenduste juures kooseksisteerivad samakujulised mitte-eestikeelsed sünonüümid ja ühendab need üheks kõigi nende keelendite tähenduste kontekstides. Leitud keelenditega seotud andmed kolitakse kordumatult sihtkeelendite juurde ja liigsed homonüümid kustutatakse. Eelistatud on detailsed sihtkeelendid. Enne käivitamist pööra tähelepanu eeldustele!

Vaikimisi määrab vastav ehitamise/käivitamise profiil terminalipõhise logimise.

Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvsimwordsum
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvsimwordsum
```

Eeldused enne käivitamist!

- Tähenduste ühendamine koos kõigi oma eeldustega

Korduvate tähendusnumbrite korrigeerimine

Loodud on käsureapõhine rakendus, mis järjestab keelendite korduvate tähendusnumbritega ilmikud. Rakendus ei vaja käivitamisel mingeid argumente. Rakendust on ohutu korduvalt käivitada. Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvsortlexlevels
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvsortlexlevels
```

Vene keele rõhkude teisendamine

Loodud on käsureapõhine utiliit vene keele rõhkude teisendamiseks juba andmebaasis eksisteerivast algsest EKI märgendusest uue süntaksiga EKI märgenduseks. Uus märgendus on juba kasutusel nii Ekilexi kui Sõnaveebi kuvades.

Kui ehitamise profiilile vastavas määrangute failis `ultima-loader.properties` seadistada `doreports=true` siis genereeritakse raport juhtumitest kus juba eksisteeriv sihtmärgendus on vastuolus lähtemärgendusega.

Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvmergeruswordstress
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvmergeruswordstress
```

Eeldused enne käivitamist!

- Käivita skript: Lisad > Andmeparandusskriptid > Tarbetu vene rõhu märgenduse eemaldamine

Vene ja ladina homonüümide ühendamine

Loodud on käsureapõhine vene ja ladinakeelsete homonüümide ühendamise utiliit. Rakenduse käivitamisel tuleb ette anda käsitletav keelekood ja võib ette anda tekstifaili, mis sisaldab

ignoreeritud keelendite väärtuseid. Testitud on järgneva failiga:

<https://gist.github.com/arvitavast/1c33014615b521e97d0fac53b242bb67>

Vene keele puhul rakendub täiendav loogika keelendite rõhkude arvestamiseks.

Kui ehitamise profiilile vastavas määrangute failis `ultima-loader.properties` seadistada `doreports=true` ja keelekood on „rus“ siis genereeritakse kokku neli raportit juhtumitest kus rõhkude andmed on erineval viisil ühendamist pärssinud.

Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvlangbasedwordsum
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvlangbasedwordsum  
-Dexec.args="rus /var/apps/data/venehomod/venehomod.txt"
```

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvlangbasedwordsum  
-Dexec.args="lat"
```

Rakendust on ohutu korduvalt käivitada

Eeldused enne käivitamist!

- Vt peatükk „Vene keele rõhkude teisendamine“

Homonüüminumbrite järjestamine

Loodud on andmebaasi protseduur, mis likvideerib samakujuliste keelendite korduvad homonüüminumbrid ning ühtlasi järjestab homonüüminumbrid ümber absoluutse eelistusega tõsta „EKI ühendsõnastik“-u (sss) kuuluvusega keelendid esimeseks ja korduva homonüüminumbri korral keelendite loomise järjekorra alusel.

Erineval viisil sõnakogude lisandumisel võib olla vajalik protseduuri korduvalt käivitada.

Lisad > Andmeparandusskriptid > Homonüüminumbrite järjestamine

Sünonüümikandidaatide genereerimine

Loodud on käsureapõhine sünonüümikandidaatide laadur, mis loob andmebaasi keelendite seosed koos korpuse sagedustega.

Generaatori sisendiks on CSV-vormingus fail, mis koostatakse sõnastikest ja korpustest. Küsi faili arendajate käest.

Ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvngenraw
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvngenraw  
-Dexec.args="<impordifaili rada>"
```

Tähelepanu! Protsess on aeganõudev!

Sõnakogude eksportimine

Loodud on käsureapõhine sõnakogude ekspordi rakendus, mis etteantud sõnakogu andmed võimalikult täielikul kujul struktuurselt ja hierarhiliselt JSON formaadis faili kirjutab, mis omakorda ZIP formaadis pakitakse. Fail võib sisaldada korduseid (allikad, kollokatsioonid, keelendi grupid). Tulevase sõnakogu impordi funktsionaalsuse jaoks on rangelt soovitatav faili sisu mitte käsitsi muuta. Rakendus küsib otse käsurea konsoolis sisendiks eksporditava sõnakogu koodi, kinnitust avalike või kõigi andmete ekspordiks ja kataloogi rada kuhu ekspordi tulem kirjutada. Kataloog peab eelnevalt eksisteerima. Seoses konsoolipõhise dialoogiga peab rakenduse logi konf olema samuti konsoolipõhine (mitte failipõhine). Seepärast on rakenduse Maveni profiil konfigureeritud kasutama hoopis rada

```
/ekilex/ekilex-etl/envresources/prodc/
```

Seal tuleb seadistada andmebaasi ühendus failis ekilex-etl.properties või kopeerida juba seadistatud samanimeline olemasolev fail, mis on kasutuses teiste etl-mooduli rakenduste jaoks. Kuna rakendusel puuduvad muud funktsionaalsed määrangud, siis võib järgmiseks rakenduse ehitada.

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvdsexp
```

Käivitamine:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvdsexp
```

Rakendus automaatselt analüüsib eksisteeriva andmebaasi tabeleid ja nende relatsioone sellisena nagu nad sel hetkel eksisteerivad. Seetõttu on antud rakendus paindlik ja tarkvara versioonist sõltumatu.

Sõnakogude importimine

Loodud on käsureapõhine sõnakogude impordi rakendus, mis spetsifikatsioonile vastava struktuuriga failidest loob või täiendab sõnakogusid.

Rakendusel on kolm funktsiooni:

- Reaalse andmebaasi pealt struktuurielementide kirjelduse koostamine
- Sõnakogu impordifaili valideerimine ja terviklikkuse kontroll koos tulemuse raporteerimisega uue sõnakogu loomise kontekstis
- Sõnakogu importimine selle loomisega
- Sõnakogu importimine selle täiendamisega

Rakenduse konfiguratsioon asub kataloogis:

```
/ekilex/ekilex-etl/envresources/prodc/
```

Rakenduse ehitamine:

```
/ekilex/ekilex-etl>mvn clean install -D skipTests -P prodsrvdsimp
```

Rakenduse käivitamine neljas erinevas funktsioonis:

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvdsimp -Dexec.args="tables"
```

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvdsimp -Dexec.args="validate  
<impordifaili rada>"
```

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvdsimp -Dexec.args="import  
create <impordifaili rada>"
```

```
/ekilex/ekilex-etl>mvn exec:java -P prodsrvdsimp -Dexec.args="import  
append <impordifaili rada>"
```

Failide ja andmete struktuuri täpsem kirjeldus asub siin:

<https://github.com/tripledev/ekilex/wiki/S%C3%B5nakogude-import>

Ekspluatatsiooni märkused

Kasutajatega seotud kirjete varundamine sõnakogude täis-laadimisel

Kui on soov täis-laadida kõik sõnakogud, aga säilitada kasutajatega ja muu haldusega seotud andmed, siis on soovitatav kopeerida järgmiste tabelite sisu (kui need selles versioonis eksisteerivad):

```
eki_user, eki_user_application, eki_user_profile, dataset_permission
```

Et antud kirjete taastamisel säiliks korrektne relatsioonilisus, siis tuleb teadlikult juhtida PK (*Primary Key*) genereerimise ja ise määramise vahel arvestusega, et rakendus ise loob kirjeid kasutades automaatsed PK genereerimise jadasid (*sequence*). Seepärast peab vastavaid jadasid üle-häälestama juhul kui PK-sid on sisestatud käsitsi.

Üks lahendus on varundada nimetatud tabelite kirjed *insert* klauslitena ilma PK väärtusteta sorteerituna kohaliku PK järgi.

Oluline! Kui olemasolevas andmebaasis puudub tabel `eki_user_profile`, siis tuleb see käsitsi luua ja sisustada peale kasutajate laadimist skriptiga:

```
insert into eki_user_profile (user_id) (select id from eki_user);
```

Rakenduse URL kodeeringute probleemistik

Selleks, et rakenduse URL rajad saaksid sisaldada nõ eksootilisi ja reserveeritud sümboleid, peab

rakendus vastavaid väärtuseid teadlikult kodeerima enne URL-i lisamist ja dekodeerima pärast URL-st lugemist. Paraku erinevad teegid ja filtrid võivad kasutada erinevaid kodeerimise reegleid ning lisaks rakendada iseseisvalt kodeerimist tingimuslikult sõltuvalt millised sümbolid URL-s sisalduvad vaatamata sellele, et URL on juba kodeeritud. Oleme märganud, et Apache HTTP server võib teatud tingimustel meelevaldselt ja soovimatult manipuleerida URL-e (eriti vene keelsete väärtustega URL-de puhul), kui selle määrangutes vastavat keeldu pole. Soovitame täiendada HTTP serveri rakenduste viidete määranguid „nocanon“ võtmega:

```
...  
ProxyPass ajp://localhost:5577/wordweb nocanon  
...
```

Sõnakogude haldus ja õigused

Kõikidel laetud sõnakogudel tuleb enne kasutuselevõttu ja muutmist/täiendamist Ekilexis „Sõnakogude haldus“ lehel lisada kasutatavad klassifikaatorid. Vastavate klassifikaatorite valikud vastavates sõnakogudes on sisu muutmisel/täiendamisel piiritletud just selliste väärtustega. Vastasel juhul on valikud tühjad.

Sõnakogude haldamiseks peab kasutajal olema kas administraatori staatus või vastava sõnakogu omaniku õigus. Sõnakogu omaniku õigus laiendab muutmise õigust.

Sõnakogu sisu muutmiseks peab olema valitud vastava sõnakogu muutmise roll. Muutmise rolli on võimalik valida ainult juhul kui kasutajale on antud „Õiguste haldus“ lehel vastav muutmise õigus. Iga kasutaja võib otsida ja näha kõigi sõnakogude sisu, mis on olekus „avalik“. Kasutaja saa näha ka muudes olekutes sisu, kui tal on vastava sõnakogu muutmise õigus.

Administraatori staatusega kasutaja saab näha kõigi sõnakogude kogu sisu sõltumata olekust, kuid ei saa muuta seda.

Uuenevate tarkvaraversioonide migratsioon

Kuna alates Ekilex tarkvaraversioonist 1.8.0 alates on tarkvara hakatud toodangus kasutama sihtotstarbepäraselt ning andmebaasi tekib uusi andmeid, mida sõnakogude täislaadimisega ei saa korvata, aga tarkvaraarendus jätkuvalt täiendab ja muudab andmebaasi struktuure, siis edaspidi on oluline jälgida kokkuleppelist uuenduste migratsiooni protsessi.

- Kui toimub valikuliste sõnakogude taas-laadimine, siis UltimaLoader-i konfiguratsioonis kindlasti mitte unustada `isfullreload=false` !
- Enne uuendatud tarkvara käivitamist, jooksutada andmebaasis järgnev skript:

```
ekilex/eki-common/src/main/resources/sql/delivery.sql
```

Palun jälgige ka kommentaare selles skriptis. Võimalik, et muudatused tabelistruktuurides tingivad mingite muude skriptide taaskäivitamise.

Lisad

Andmeparandusskriptid

Vastete järjestuse taastamine komponentsõnakogudest

```
update lexeme
  set order_by = l.ev_qq_order_by
from (select l1.id lexeme_id,
            (array_agg(l2.order_by order by l2.dataset_code))[1]
ev_qq_order_by
  from lexeme l1,
       lexeme l2
 where l1.dataset_code = 'sss'
 and   l2.dataset_code in ('ev2', 'qq2')
 and   l1.word_id = l2.word_id
 and   l1.meaning_id = l2.meaning_id
 group by l1.word_id,
          l1.meaning_id,
          l1.id) l
where lexeme.id = l.lexeme_id;
```

Lihtsate vene vastete järjestuse nihutamine detailsetest tahapoole

```
update lexeme l
  set order_by = nextval('lexeme_order_by_seq')
from (select l.id
  from lexeme l,
       word w
 where l.complexity = 'SIMPLE'
 and   l.word_id = w.id
 and   w.lang = 'rus'
 order by l.order_by) lqq
where l.id = lqq.id;
```

Tarbetu vene rõhu märgenduse eemaldamine

```
update form
set value_prese = replace(value_prese, '<eki-stress>ë</eki-stress>', 'ë')
where value_prese like '%<eki-stress>ë</eki-stress>%';
```

Homonüüminumbrite järjestamine

```
-- ajutine andmetüüp
create type temp_word_data_tuple as (word_id bigint, homonym_nr integer);

do $$
<<adj_homon_nr_block>>
declare
    ordered_homonym_nrs_str_pattern text := array_to_string(array (select
generate_series(1, 100)), '-', '');
    word_row record;
    adj_word_ids temp_word_data_tuple;
    homonym_nr_iter integer;
begin
    for word_row in
        (select w.word,
            w.lang,
            w.word_ids
        from (select w.word,
            w.lang,
                array_agg(row(w.id, w.homonym_nr)::temp_word_data_tuple
order by w.ds_order_by, w.homonym_nr, w.id) word_ids,
                array_to_string(array_agg(w.homonym_nr order by
w.ds_order_by, w.homonym_nr), '-') homonym_nrs_str
        from (select w.id,
            (array_agg(distinct f.value))[1] word,
            w.homonym_nr,
            w.lang,
            (select case
                when count(l.id) > 0 then 1
                else 2
            end
            from lexeme l
            where l.word_id = w.id
            and l.type = 'PRIMARY'
            and l.dataset_code = 'sss') ds_order_by
        from word w,
            paradigm p,
            form f
        where exists (select l.id
            from lexeme l
            where l.word_id = w.id
            and l.type = 'PRIMARY')
        and p.word_id = w.id
        and f.paradigm_id = p.id
        and f.mode = 'WORD'
        group by w.id) w
```

```
        group by w.word,
                w.lang) w
    where ordered_homonym_nrs_str_pattern not like w.homonym_nrs_str ||
'%'
    order by w.lang,
            w.word)
loop
    homonym_nr_iter := 1;
    foreach adj_word_ids in array word_row.word_ids
    loop
        if homonym_nr_iter != adj_word_ids.homonym_nr then
            update word set homonym_nr = homonym_nr_iter where id =
adj_word_ids.word_id;
        end if;
        homonym_nr_iter := homonym_nr_iter + 1;
    end loop;
end loop;
end adj_homon_nr_block $$;

drop type temp_word_data_tuple;
```

Juhendi lõpp

(Dokument täieneb jooksvalt. Jälgi dokumendi kuupäeva!)